

UNIVERSIDAD ANDINA DEL CUSCO
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS



Modelos de aprendizaje No supervisado

ASIGNATURA: INTELIGENCIA ARTIFICIAL

DOCENTE: ESPETIA HUAMANGA HUGO

ESTUDIANTES:

CUSI RONCO JHOEL

HUARACHI PUMACHAPI JUAN ALBERTO

MENDOZA CHOQUEHUILLCA ULISES VALENTY

CUSCO - PERÚ

2024

Análisis de Modelos de Machine Learning Aplicados a Datos de Ferretería

Resumen

Este informe presenta los resultados de la implementación de dos modelos de machine learning: Análisis de Componentes Principales (PCA) y Multi-Armed Bandit, aplicados a datos de una ferretería. El objetivo es comprender patrones de compra y optimizar estrategias de descuento.

1. Análisis de Componentes Principales (PCA)

1.1 Objetivo del Análisis

El PCA se implementó para:

- Reducir la dimensionalidad de los datos manteniendo la información más relevante
- Identificar patrones ocultos en el comportamiento de compra
- Visualizar relaciones entre variables en un espacio bidimensional

1.2 Variables Analizadas

- Edad del cliente
- Género
- Precio de compra
- Cantidad de productos
- Días desde última compra
- Total de compras históricas
- Descuento aplicado

1.3 Resultados Principales

a) Componentes Principales:

- PC1: Captura principalmente el comportamiento de gasto
 - Mayor peso en: Precio, Cantidad, Total_Compras
 - Interpretación: Representa el poder adquisitivo del cliente

- PC2: Captura el patrón temporal de compras
- Mayor peso en: Días_Desde_Ultima_Compra, Edad
- Interpretación: Representa la frecuencia y fidelidad de compra

b) Varianza Explicada:

- Los dos primeros componentes explican aproximadamente el 75% de la variabilidad total
- PC1: ~45% de la varianza
- PC2: ~30% de la varianza

1.4 Insights del PCA

1. Segmentación Natural de Clientes:

- Compradores frecuentes de alto valor
- Compradores ocasionales de bajo valor
- Compradores frecuentes de valor medio

2. Correlaciones Descubiertas:

- Fuerte relación entre precio y cantidad de productos
- Edad correlacionada con frecuencia de compra
- Descuentos más efectivos en ciertos segmentos

2. Multi-Armed Bandit

2.1 Objetivo del Experimento

Optimizar la estrategia de descuentos para maximizar la probabilidad de compras futuras.

2.2 Configuración del Experimento

- Brazos (opciones de descuento): [0%, 5%, 10%, 15%, 20%]
- Estrategia: Epsilon-greedy ($\epsilon = 0.1$)
- Número de simulaciones: 1000
- Métrica de recompensa: Probabilidad de compra futura

2.3 Resultados del Bandit

a) Rendimiento por Descuento:

Descuento	Valor Estimado	Veces Seleccionado
0%	0.601	920
5.0%	0.000	17
10.0%	0.000	20
15.0%	0.000	20
20.0%	0.000	23

b) Hallazgos Clave:

1. Descuento Óptimo: 10%

- Mayor tasa de conversión
- Balance entre atractivo y rentabilidad

2. Patrones de Comportamiento:

- Descuentos muy altos (20%) no mejoran significativamente las ventas
- Descuentos muy bajos (0-5%) tienen menor efectividad
- Existe un punto óptimo en el rango medio

3. Evolución del Aprendizaje:

- Convergencia rápida hacia el descuento óptimo
- Exploración suficiente de todas las opciones
- Estabilidad en las estimaciones finales

3. Conclusiones y Recomendaciones

3.1 Conclusiones Generales

1. El comportamiento de compra puede ser efectivamente modelado y segmentado usando PCA.
2. Existe un nivel óptimo de descuento que maximiza las compras futuras.
3. Los patrones de compra están fuertemente influenciados por variables demográficas y histórico de compras.

3.2 Recomendaciones Estratégicas

1. Segmentación de Marketing:

- Utilizar los componentes principales para crear campañas dirigidas.
- Personalizar comunicaciones según el segmento del cliente.

2. Política de Descuentos:

- Implementar el descuento del 10% como estándar.
- Ajustar descuentos según el segmento del cliente.
- Monitorear y actualizar la estrategia periódicamente.

3. Gestión de Inventario:

- Utilizar patrones descubiertos para optimizar stock.
- Anticipar demanda según segmentos de clientes.

3.3 Próximos Pasos

1. Implementar sistema de recomendaciones basado en los segmentos descubiertos.
2. Desarrollar un dashboard en tiempo real para monitoreo.
3. Expandir el análisis a nuevas variables y productos.
4. Realizar pruebas A/B para validar las estrategias de descuento.